Reto-> Entrega 2 (18/11) -> Clasificación-ensambles y presentación ejecutiva

Domingo, Nov 13 2022

Objetivo: Implementar conocimientos adquiridos a lo largo de curso en el desarrollo de un proyecto con datos reales.

Alumno: César Iván Pedrero Martínez

• Matrícula: A01366501

• Profesor: Julio César Galindo López

Parte 1: Verificar la limpieza.

```
In [878]:
```

```
import numpy as np
import os.path
import pandas as pd
```

In [879]:

```
DATASET_PATH = "../data/"
DATASET_NAME = "Datos_de_calidad_del_agua_de_sitios_de_monitoreo_de_aguas_subterraneas_20
20.csv"
```

In [880]:

```
def warn(msg):
    """
    Simple replacement to the warning method
    from the common library. Prints a given message
    with a warning prefix.
    """
    warnPrefix = "[WARNING]"
    print(warnPrefix, msg)

def log(msg, start=" ", end="\n"):
    """
    Simple replacement to the print method
    from the common library. Prints a given message
    with a log prefix.
    """
    logPrefix = "[INFO]" + start
    print(logPrefix + str(msg), end=end)
```

In [881]:

```
def showRowsWithNan(df: pd.DataFrame, col: str) -> pd.DataFrame:
    """
    Gets the rows from a column with NaN values.
    """
    log("Showing current rows containing NaN for the {} column:".format(col))
    return df[df[col].isna()]

def showRowsWithNanMultiColumn(df: pd.DataFrame, colArray: list) -> pd.DataFrame:
    """
    Gets the rows from a column with NaN values.
    """
    log("Showing current rows containing NaN for the {} columns:".format(colArray))
    nanDF = df[df[colArray].isna().any(axis=1)]
    return nanDF[colArray]
```

```
def showColumnswithNaN(df: pd.DataFrame) -> pd.DataFrame:
    11 11 11
    Shows all the columns in the data frame along with a
   boolean value that indicates if the column has NaN values
    or not.
   log("Showing current column NaN state:")
   return df.isna().any()
def showUniques(df: pd.DataFrame, col: str) -> list:
   Returns the unique values of a given column
   in the data frame.
   log("Showing unique values for the {} column:".format(col))
   return df[col].unique()
def showAllDataframeTypes(df) -> pd.DataFrame:
   Shows each column of the data frame
    along with its current data type.
    return df.dtypes
```

In [882]:

df = pd.read_csv(os.path.join(DATASET_PATH, DATASET_NAME), encoding='latin1', index_col=
[0])
df

Out[882]:

	CLAVE	SITIO	ORGANISMO_DE_CUENCA	ESTADO	MUNICIPIO	ACUIFERO S	S
0	DLAGU6	POZO SAN GIL	LERMA SANTIAGO PACIFICO	AGUASCALIENTES	ASIENTOS	VALLE DE CHICALOTE	
1	DLAGU6516	POZO R013 CAÃADA HONDA	LERMA SANTIAGO PACIFICO	AGUASCALIENTES	AGUASCALIENTES	VALLE DE CHICALOTE	
2	DLAGU7	POZO COSIO	LERMA SANTIAGO PACIFICO	AGUASCALIENTES	cosio	VALLE DE AGUASCALIENTES	
3	DLAGU9	POZO EL SALITRILLO	LERMA SANTIAGO PACIFICO	AGUASCALIENTES	RINCON DE ROMOS	VALLE DE AGUASCALIENTES	
4	DLBAJ107	RANCHO EL TECOLOTE	PENINSULA DE BAJA CALIFORNIA	BAJA CALIFORNIA SUR	LA PAZ	TODOS SANTOS	
1063	OCRBR5101M1	L-310 (COMUNIDAD SAN MANUEL)	RIO BRAVO	NUEVO LEON	LINARES	CITRICOLA SUR	
1064	OCRBR5102M1	L-305 (EJIDO OJO DE AGUA LAS CRUCESITAS)	RIO BRAVO	NUEVO LEON	LINARES	CITRICOLA SUR	
1065	OCRBR5105M2	HACIENDA MEXIQUITO POZO 01	RIO BRAVO	NUEVO LEON	CADEREYTA JIMENEZ	CITRICOLA NORTE	
1066	OCRBR5106M1	COMUNIDAD LOS POCITOS	RIO BRAVO	NUEVO LEON	GALEANA	NAVIDAD-POTOSI- RAICES	
1067	OCRBR5109M1	COMUNIDAD LA REFORMA	RIO BRAVO	NUEVO LEON	GALEANA	NAVIDAD-POTOSI- RAICES	

```
In [883]:
```

df.dtypes

Out[883]:

CLAVE object SITIO object object ORGANISMO DE CUENCA object ESTADO MUNICIPIO object object ACUIFERO SUBTIPO object LONGITUD float64 LATITUD float64 PERIODO int64 ALC mg/L float64 CALIDAD ALC object CONDUCT_mS/cm float64 CALIDAD_CONDUC object SDT M mg/L SDT_M_mg/L CALIDAD_SDT_ra float64 object CALIDAD SDT salin object FLUORUROS mg/L float64 CALIDAD FLUO object DUR mg/L float64 CALIDAD DUR object COLI FEC NMP/100 mL float64 CALIDAD COLI FEC object N NO3 mg/L float64 CALIDAD N NO3 object AS TOT mg/L float64 CALIDAD AS object CD TOT mg/L float64 CALIDAD CD object CR TOT mg/L float64 CALIDAD CR object HG TOT mg/L float64 CALIDAD HG object PB TOT mg/L float64 CALIDAD PB object MN TOT mg/L float64 CALIDAD MN object FE TOT mg/L float64 CALIDAD FE object object SEMAFORO CONTAMINANTES object int64 CUMPLE CON ALC CUMPLE_CON_COND int64 CUMPLE_CON_SDT_ra CUMPLE_CON_FLUO int64 int64 CUMPLE_CON_DUR int64 CUMPLE_CON_CF int64 CUMPLE CON NO3 int64 CUMPLE_CON_AS CUMPLE_CON_CD int64 CUMPLE_CON CR int64 CUMPLE CON HG int64 CUMPLE CON PB int64 CUMPLE CON MN int64 CUMPLE CON FE int64 dtype: object

In [884]:

showColumnswithNaN(df)

[INFO] Showing current column NaN state:

Out[884]:

CT ATE

```
СТЧАГ
                       гатье
SITIO
                       False
ORGANISMO DE CUENCA
                      False
ESTADO
                       False
MUNICIPIO
                      False
ACUIFERO
                      False
SUBTIPO
                      False
LONGITUD
                      False
TATTTUD
                      False
PERIODO
                      False
ALC_mg/L
                      False
CALIDAD_ALC
                      False
CONDUCT_mS/cm
                       False
CALIDAD_CONDUC
                      False
SDT M mg/L
                       False
CALIDAD_SDT_ra
                       False
CALIDAD_SDT_salin
FLUORUROS_mg/L
                       False
                       False
CALIDAD FLUO
                       False
DUR mg/L
                      False
CALIDAD DUR
                      False
COLI_FEC_NMP/100_mL False
CALIDAD_COLI_FEC False
N NO3 mg/L
                      False
CALIDAD N NO3
                      False
AS TOT mg/L
                      False
CALIDAD AS
                      False
CD TOT mg/L
                      False
CALIDAD CD
                      False
CR_TOT_mg/L
                      False
CALIDAD CR
                      False
HG_TOT_mg/L
                      False
CALIDAD HG
                      False
                       False
PB TOT mg/L
CALIDAD PB
                       False
MN TOT_mg/L
                       False
CALIDAD_MN
FE_TOT_mg/L
                       False
                       False
CALIDAD_FE
                      False
SEMAFORO
                      False
                      False
CONTAMINANTES
CUMPLE CON ALC
                      False
CUMPLE_CON_COND False
CUMPLE_CON_SDT_ra False
CUMPLE_CON_SDT_salin False
CUMPLE_CON_FLUO False
CUMPLE CON DUR
                      False
CUMPLE CON CF
                      False
CUMPLE CON NO3
                      False
CUMPLE CON AS
                      False
                      False
CUMPLE CON CD
CUMPLE CON CR
                       False
CUMPLE CON HG
                       False
CUMPLE CON PB
                       False
CUMPLE_CON_MN
                       False
CUMPLE CON FE
                       False
dtype: bool
```

In [886]:

Parte 2: Modificación de variables categóricas.

```
In [885]:
# We'll need a copy of the target just for visualization at the end.
df["SEMAFORO_str"] = df["SEMAFORO"]
```

```
# Let's see what are the categorical values.
categoricalColumns = list(df.select_dtypes(exclude=["int64","bool_", "float64"]).columns
)
```

```
categoricalColumns.remove("CLAVE") # Id, not needed in processing.
categoricalColumns.remove("SITIO") # Specific name, not needed in processing.
categoricalColumns.remove("CONTAMINANTES") # Comma separated values, will handle separate
categoricalColumns.remove ("SEMAFORO str") # Copy just for visualization at the end.
categoricalColumns
Out[886]:
['ORGANISMO DE CUENCA',
 'ESTADO',
 'MUNICIPIO',
 'ACUIFERO',
 'SUBTIPO',
 'CALIDAD ALC',
 'CALIDAD CONDUC',
 'CALIDAD SDT ra',
 'CALIDAD SDT salin',
 'CALIDAD_FLUO',
 'CALIDAD DUR',
 'CALIDAD COLI FEC',
 'CALIDAD N NO3',
 'CALIDAD AS',
 'CALIDAD CD',
 'CALIDAD CR',
 'CALIDAD HG',
 'CALIDAD PB',
 'CALIDAD MN',
 'CALIDAD FE',
 'SEMAFORO']
In [887]:
# There's a column that has values comma separated, let's start with that. We need to one
-hot encode them into separated columns.
df = pd.concat([df.drop("CONTAMINANTES", 1), df["CONTAMINANTES"].str.qet dummies(sep=","
).add prefix("CONTAMINANTES ")], 1)
/var/folders/3z/3340wyws0q3fr4z6 yx4yc7r0000gn/T/ipykernel 48067/1746299027.py:3: FutureW
arning: In a future version of pandas all arguments of DataFrame.drop except for the argu
ment 'labels' will be keyword-only.
 df = pd.concat([df.drop("CONTAMINANTES", 1), df["CONTAMINANTES"].str.get dummies(sep=",
").add prefix("CONTAMINANTES ")], 1)
/var/folders/3z/3340wyws0q3fr4z6 yx4yc7r0000qn/T/ipykernel 48067/1746299027.py:3: FutureW
arning: In a future version of pandas all arguments of concat except for the argument 'ob
js' will be keyword-only.
 df = pd.concat([df.drop("CONTAMINANTES", 1), df["CONTAMINANTES"].str.get dummies(sep=",
").add prefix("CONTAMINANTES ")], 1)
In [888]:
df.columns
Out[888]:
Index(['CLAVE', 'SITIO', 'ORGANISMO DE CUENCA', 'ESTADO', 'MUNICIPIO',
        'ACUIFERO', 'SUBTIPO', 'LONGITUD', 'LATITUD', 'PERIODO', 'ALC mq/L',
       'CALIDAD ALC', 'CONDUCT mS/cm', 'CALIDAD CONDUC', 'SDT M mg/L,
       'CALIDAD SDT ra', 'CALIDAD_SDT_salin', 'FLUORUROS_mg/L', 'CALIDAD_FLUO',
       'DUR mg/L', 'CALIDAD DUR', 'COLI FEC NMP/100 mL', 'CALIDAD COLI FEC',
       'N NO3 mg/L', 'CALIDAD_N_NO3', 'AS_TOT_mg/L', 'CALIDAD_AS',
       'CD_TOT_mg/L', 'CALIDAD_K_NOS', AS_IOT_mg/L', 'CALIDAD_CR', 'HG_TOT_mg/L', 'CALIDAD_HG', 'PB_TOT_mg/L', 'CALIDAD_PB', 'MN_TOT_mg/L', 'CALIDAD_MN', 'FE_TOT_mg/L', 'CALIDAD_FE', 'SEMAFORO', 'CUMPLE_CON_ALC', 'CUMPLE_CON_COND', 'CUMPLE_CON_SDT_salin', 'CUMPLE_CON_SDT_salin',
```

'CUMPLE_CON_FLUO', 'CUMPLE_CON_DUR', 'CUMPLE_CON CF', 'CUMPLE CON NO3',

'CUMPLE_CON_AS', 'CUMPLE_CON_CD', 'CUMPLE_CON_CR', 'CUMPLE_CON_HG', 'CUMPLE_CON_PB', 'CUMPLE_CON_MN', 'CUMPLE_CON_FE', 'SEMAFORO_str',

'CONTAMINANTES_ALC', 'CONTAMINANTES_AS', 'CONTAMINANTES_CD', 'CONTAMINANTES CF', 'CONTAMINANTES CONDUC', 'CONTAMINANTES CR',

```
'CONTAMINANTES_DT', 'CONTAMINANTES_FE', 'CONTAMINANTES_FLUO',
'CONTAMINANTES_HG', 'CONTAMINANTES_MN', 'CONTAMINANTES_NI',
'CONTAMINANTES_NINGUNO', 'CONTAMINANTES_NO3', 'CONTAMINANTES_PB',
'CONTAMINANTES_SDT_ra', 'CONTAMINANTES_SDT_salin'],
dtype='object')
```

In [889]:

Now let's encode the other categorical values.
I'd like to keep the other categories as label encoder as they are not comma separated
and a single target column is easier to manage.

from sklearn.preprocessing import LabelEncoder

labelencoder = LabelEncoder()

df[categoricalColumns] = df[categoricalColumns].apply(labelencoder.fit transform)

Out[889]:

	CLAVE	SITIO	ORGANISMO_DE_CUENCA	ESTADO	MUNICIPIO	ACUIFERO	SUBTIPO	LONGITUD	LA1
0	DLAGU6	POZO SAN GIL	6	0	25	232	5	-102.02210	22.
1	DLAGU6516	POZO R013 CAÃADA HONDA	6	0	9	232	5	-102.20075	21.
2	DLAGU7	POZO COSIO	6	0	94	228	5	-102.28801	22.
3	DLAGU9	POZO EL SALITRILLO	6	0	284	228	5	-102.29449	22.
4	DLBAJ107	RANCHO EL TECOLOTE	10	2	197	220	5	-110.24480	23.
1063	OCRBR5101M1	L-310 (COMUNIDAD SAN MANUEL)	12	18	204	42	5	-99.54191	24.
1064	OCRBR5102M1	L-305 (EJIDO OJO DE AGUA LAS CRUCESITAS)	12	18	204	42	5	-99.70099	24.
1065	OCRBR5105M2	HACIENDA MEXIQUITO POZO 01	12	18	45	41	5	-99.82249	25.
1066	OCRBR5106M1	COMUNIDAD LOS POCITOS	12	18	134	137	5	-100.32683	24.
1067	OCRBR5109M1	COMUNIDAD LA REFORMA	12	18	134	137	5	-100.73302	25.

1068 rows × 73 columns

In [890]:

df.dtypes

Out[890]:

CLAVE	object		
SITIO	object		
ORGANISMO_DE_CUENCA	int64		
ESTADO	int64		
MUNICIPIO	int64		
CONTAMINANTES NINGUNO	int64		

```
CONTAMINANTES_NO3 int64
CONTAMINANTES_PB int64
CONTAMINANTES_SDT_ra int64
CONTAMINANTES_SDT_salin int64
Length: 73, dtype: object
```

Parte 3: Análisis de la importancia de las variables.

3.1: Creación del modelo.

Out[897]:

```
In [891]:
from sklearn import metrics
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification report, confusion matrix, accuracy score
from sklearn.model selection import train test split
from sklearn.preprocessing import StandardScaler
import matplotlib.pyplot as plt
from collections import defaultdict
In [892]:
targetLabel = "SEMAFORO"
featuresToIgnore = ["CLAVE", "SITIO", "PERIODO", "SEMAFORO str", targetLabel]
featureLabels = [e for e in list(df.columns) if e not in featuresToIgnore]
X = df[featureLabels]
y = df[[targetLabel]]
In [893]:
X.shape
Out[893]:
(1068, 68)
In [894]:
y.shape
Out[894]:
(1068, 1)
In [895]:
X train, X test, y train, y test = train test split(X, y, test size=0.3, random state=0)
In [896]:
sc = StandardScaler()
X train = sc.fit transform(X train)
X test = sc.transform(X test)
In [897]:
model = RandomForestClassifier(n estimators=20, random state=0) # 20 estimators are just
enough.
model.fit(X train, y train)
/var/folders/3z/3340wyws0q3fr4z6 yx4yc7r0000gn/T/ipykernel 48067/886015397.py:3: DataConv
ersionWarning: A column-vector y was passed when a 1d array was expected. Please change t
he shape of y to (n samples,), for example using ravel().
  model.fit(X train, y train)
```

```
RandomForestClassifier
RandomForestClassifier(n estimators=20, random state=0)
In [898]:
# Let's evaluate the model.
y pred = model.predict(X test)
In [899]:
print(confusion_matrix(y_test, y_pred))
[[ 73 0
           0]
   3 113
 [
           0]
 [ 0
      0 132]]
In [900]:
print(classification_report(y_test, y_pred))
             precision recall f1-score
                                              support
           0
                  0.96
                           1.00
                                     0.98
                                                  73
           1
                  1.00
                           0.97
                                     0.99
                                                  116
           2
                  1.00
                            1.00
                                      1.00
                                                  132
                                      0.99
                                                  321
   accuracy
                 0.99
                           0.99
                                     0.99
                                                 321
  macro avg
weighted avg
                 0.99
                            0.99
                                      0.99
                                                 321
In [901]:
accuracy score(y test, y pred)
Out[901]:
0.9906542056074766
3.2: Análisis de las varaibles.
In [902]:
importance = model.feature importances
In [903]:
def getImportanceDictionary():
    Returns an ordered representation of
    the importances in a dictionary.
    dic = defaultdict(lambda: 0)
    for i, v in enumerate(importance):
       dic[featureLabels[i]] = v
    return dict(sorted(dic.items(), key=lambda item: item[1], reverse=True))
def showMostImportantFeatures(n: int = 5):
    Prints the most important features.
    dic = getImportanceDictionary()
    count = 0
```

for key in dic:

```
log("Feature: %s, Score: %.5f" % (key, dic[key]))
count += 1
if count >= n:
    return
```

In [904]:

```
# Lets get the most important features.
showMostImportantFeatures(len(featureLabels))
[INFO] Feature: CONTAMINANTES_NINGUNO, Score: 0.14885
[INFO] Feature: FLUORUROS mg/L, Score: 0.06721
[INFO] Feature: DUR mg/L, Score: 0.06480
[INFO] Feature: CALIDAD FLUO, Score: 0.05781
[INFO] Feature: N NO3 mg/L, Score: 0.05022
[INFO] Feature: CONTAMINANTES FLUO, Score: 0.04156
[INFO] Feature: CUMPLE_CON_FLUO, Score: 0.03869
[INFO] Feature: COLI FEC NMP/100 mL, Score: 0.03720
[INFO] Feature: CUMPLE_CON_AS, Score: 0.03207
[INFO] Feature: CALIDAD DUR, Score: 0.03060
[INFO] Feature: CONTAMINANTES AS, Score: 0.02837
[INFO] Feature: CUMPLE_CON_NO3, Score: 0.02790
[INFO] Feature: CONDUCT mS/cm, Score: 0.02537
[INFO] Feature: CUMPLE CON MN, Score: 0.02370
[INFO] Feature: MN TOT mg/L, Score: 0.02232
[INFO] Feature: CUMPLE CON DUR, Score: 0.02171
[INFO] Feature: CUMPLE CON FE, Score: 0.02021
[INFO] Feature: SDT M mg/L, Score: 0.01918
[INFO] Feature: AS TOT mg/L, Score: 0.01832
[INFO] Feature: CONTAMINANTES CF, Score: 0.01826
[INFO] Feature: CONTAMINANTES FE, Score: 0.01448
[INFO] Feature: CUMPLE CON CF, Score: 0.01396
[INFO] Feature: CONTAMINANTES NO3, Score: 0.01322
[INFO] Feature: FE TOT mg/L, Score: 0.01286
[INFO] Feature: CALIDAD FE, Score: 0.01183
[INFO] Feature: LATITUD, Score: 0.01094
[INFO] Feature: CALIDAD_N_NO3, Score: 0.01075
[INFO] Feature: ALC_mg/L, Score: 0.00971
[INFO] Feature: CALIDAD AS, Score: 0.00780
[INFO] Feature: ACUIFERO, Score: 0.00725
[INFO] Feature: CR TOT mg/L, Score: 0.00652
[INFO] Feature: LONGITUD, Score: 0.00585
[INFO] Feature: CALIDAD MN, Score: 0.00572
[INFO] Feature: CUMPLE CON CR, Score: 0.00548
[INFO] Feature: CONTAMINANTES ALC, Score: 0.00505
[INFO] Feature: CALIDAD CONDUC, Score: 0.00494
[INFO] Feature: ESTADO, Score: 0.00487
[INFO] Feature: CUMPLE CON COND, Score: 0.00483
[INFO] Feature: PB TOT mg/L, Score: 0.00482
[INFO] Feature: ORGANISMO DE CUENCA, Score: 0.00442
[INFO] Feature: MUNICIPIO, Score: 0.00428
[INFO] Feature: CALIDAD COLI FEC, Score: 0.00427
[INFO] Feature: CUMPLE CON ALC, Score: 0.00352
[INFO] Feature: CONTAMINANTES_MN, Score: 0.00329
[INFO] Feature: CONTAMINANTES DT, Score: 0.00319
[INFO] Feature: CALIDAD_CR, Score: 0.00298
[INFO] Feature: CALIDAD SDT salin, Score: 0.00268
[INFO] Feature: CALIDAD_SDT_ra, Score: 0.00267
[INFO] Feature: CALIDAD PB, Score: 0.00222
[INFO] Feature: CONTAMINANTES PB, Score: 0.00190
[INFO] Feature: HG TOT mg/L, Score: 0.00185
[INFO] Feature: CONTAMINANTES CR, Score: 0.00155
[INFO] Feature: CUMPLE CON PB, Score: 0.00123
[INFO] Feature: CONTAMINANTES NI, Score: 0.00090
[INFO] Feature: CUMPLE CON SDT salin, Score: 0.00082
[INFO] Feature: CUMPLE CON CD, Score: 0.00081
[INFO] Feature: SUBTIPO, Score: 0.00073
[INFO] Feature: CALIDAD ALC, Score: 0.00049
[INFO] Feature: CD TOT mg/L, Score: 0.00020
[INFO] Feature: CALIDAD CD, Score: 0.00019
[INFO] Feature: CALIDAD_HG, Score: 0.00019
```

```
[INFO] Feature: CONTAMINANTES_SDT_ra, Score: 0.00018
[INFO] Feature: CUMPLE_CON_SDT_ra, Score: 0.00010
[INFO] Feature: CONTAMINANTES_CONDUC, Score: 0.00008
[INFO] Feature: CUMPLE_CON_HG, Score: 0.00000
[INFO] Feature: CONTAMINANTES_CD, Score: 0.00000
[INFO] Feature: CONTAMINANTES_HG, Score: 0.00000
[INFO] Feature: CONTAMINANTES_SDT_salin, Score: 0.00000
```

In [905]:

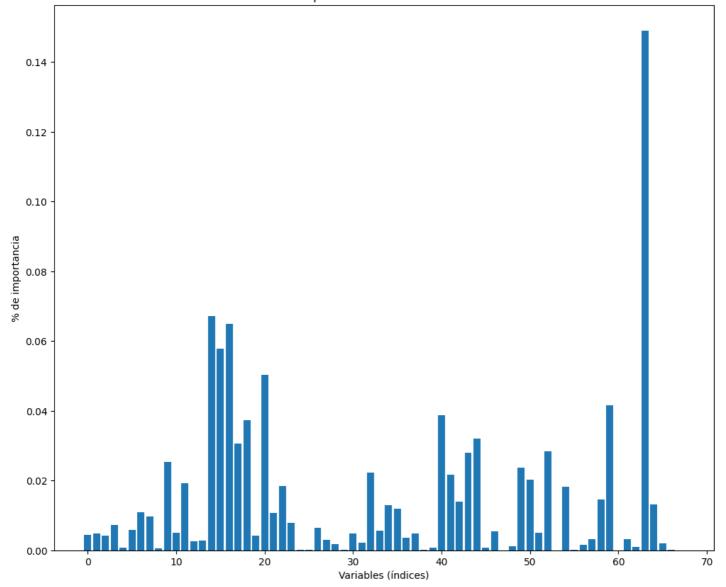
```
# Let's plot the importances.

fig, ax = plt.subplots(figsize=(12, 10))

ax.set_xlabel("Variables (indices)")
ax.set_ylabel("% de importancia")
ax.set_title("Importancia de cada variable")

plt.bar([x for x in range(len(importance))], importance)
plt.show()
```





La variable más importante, como era de esperarse, es si el agua tiene contaminantes. De ahí, podemos ver la importancia de cada contaminante en el orden de la lista y su porcentaje. Su ubicación geográfica también juega un papel importante (latitud, longitud y estado), ya que si hay una concentración más fuerte de pozos con semáforo rojo en el centro de la república (como se visualizó en el análisis con KMeans en la primer entrega del reto).

In [906]:

```
# Let's plot each pollutant.
```

```
pollutantDic = dict()
dic = getImportanceDictionary()

for (key, value) in dic.items():
    if "CONTAMINANTES_" in key and key != "CONTAMINANTES_NINGUNO":
        pollutantDic[key] = value

fig, ax = plt.subplots(figsize=(15, 8))

ax.set_xlabel("Contaminante")
ax.set_ylabel("% de importancia")
ax.set_title("Importancia de los contaminantes en el semáforo de un pozo")

plt.bar([pollutant.replace("CONTAMINANTES_", "") for pollutant in pollutantDic.keys()],
pollutantDic.values())
plt.show()
```

